

## 8-dars: Model Building-Report

**K-cross validation:** o'z-o'zidan k-ta degani, son keladi o'rniga. K-cross validation-k bo'lakli o'zaro tekshiruvdir. Modelimizni yaxshi ishlayaptimi yoki yo'qligini bahalaymiz ekan. Ya'ni bu **metriclarga** yaqin ekan.

**L-Fold cross validation: Supervised Machine Learning** model **unseen** dataset bilan qanday ishlayapti (yaxshi yoki yomon) baxolash usulidir.

Masalan, o'qituvchi o'rgatdi: o'quvchi imtixonda qanday javob berayapti: ya'ni o'qituvchi savollarni chalkashtirib va o'quvchi ko'rmagan savollar shaklida beradigan bo'lsa qanday ishlayapti yaxshimi yoki yomon o'shani baxolaymiz ekan.

**Generalization** - umumiyashtirish: bu modelning -yangi, ko'rilmagan ma'lumotlarda ham yaxshi ishlash qobiliyati.

Ya'ni model faqat **train** datasetni yodlab olmasligi kerak, balki real hayotdagi datada ham to'g'ri natija berishi kerak.

Bu nega muhim?

1) Trainda juda yaxshi

2) Testda juda yomon --> Bu esa overfitting bo'ladi.

Misol: Agar men matematikani faqat eski test savollarini yodlab o'rgansam, yangi savollarda qiynalaman. Lekin tushunib o'rgansam-har qanday savolga javob topa olaman --> bu **Generalization**.

**Classification** --Model ma'lumotni kategoriya (class) ga ajratadi.

Natija odatda:

- **0** yoki **1**
- **Ha** yoki **yo'q**
- **Spam** yoki **Not Spam** --> Misol: **Email spam**

**Regression** (uzliksiz son bashorat qiladi) -- misol uyni narxini predict qilishimiz kerak, bizda xonalar soni, etajlar, maktabga yaqinmi yo'qmi, metroga yoki katta yo'lga yaqinmi yoki yo'qmi, shunga o'xshagan featurelarni berayapmizda demak uyni narxini o'z-o'zidan o'sishi kerak. Xonasini o'lchami katta bo'lsa model o'ylaydi ha bo'ldi demak bu xonani o'lchamidan, qulayligi jihatidan narxi shunga qarab oshayotkaniga mantiqan umumiyashtiradi va bu xolat ayni--**Generalization** deyiladi.

Demak, cross-validation modelni **generalization** qobiliyatini o'lchar ekan, umumiyashtirish qobiliyatini o'lchar ekan. Chunki o'sha **generalization** bo'lmasa tasavvur qilayapsizlarmi bir 80% train qilganimizda, bizda **accuracy** 90% chiqdik deylik. Keyin esa qolgan 20% ni ko'rmaganku, 20% beradigan bo'lsak **accuracy** 70% chiqdi. Bu huddi yaxshi-yomon, oq-qora kami antomnlariga qiyoslasask bo'ladi. **Generalization (yaxshi, oq) <--> Overfitting (yomon, qora)**.

Maqsadimiz **modelni generalization qobiliyatini oshirishim** ekan uning qobiliyatini oshirish va **yaxshi generalization qilyaptimi, yaxshi umumiyashtiryaptimi** yoki yo'qmi o'shani o'lchaydigan usul bizda **cross\_validation** ekan.

Cross Validation turlari:

**1) Fold cross-validation**

- 2) Stratified K-Fold Cross Validation
- 3) Leave -One-Out Cross Validation (LOOCV)
- 4) Leave -p-out Cross Validation

**Single split** : `x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.2, random_state = 42)`

**k-fold split** : Datasetni k-ta qismlarga ajratadi, train k-1 folds va Test (qolganini qiladi) ya'ni datasetni k-ta qismiga bo'lib o'sha k dan -1 ni ayrigandan qolgani trainingga 1 tasi esa testga o'tadi.

from sklearn.model\_selection import KFold, cross\_val\_score

`kf = KFold(n_splits = 5, shuffle = True, random_state = 42)` --> bu yerda n ta qismlarga bo'l, va ularni randomly aralashtir, va model stabil ishlashi uchun random\_statega 42 ber.

`scores = cross_val_score(lr, x, y, cv=kf, scoring='r2')`

Undan so'ngra biz scoresning o'rtacha qiymatini, masivning standard og'ishi ya'ni ma'lumotlar o'racha qiymatdan qanchalik tarqalganligini (yoyilganligini) ko'rsatadi.

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

**Bu yerda:**

$\sigma$  — population standard deviation

$N$  — elementlar soni

$x_i$  — har bir qiymat

$\mu$  — population mean

$\sum$  — yig'indi

( Qisqa qilib: **Natijalar o'rtachadan qanchalik uzoqlashganini ko'rsatadi** )

Endi esa biz agar Regressionda ham foydalanamiz desak bizga **make\_scorer** classi kerak bo'ladi.

`from sklearn.metrics import make_scorer`

`mae = make_scorer(mean_absolute_error, greater_is_better = False)`

Bu yerda **greater\_is\_better = False** bo'ldi sababi bizga kichigi muhim ya'ni error qanchalik kichik bo'lsa shuncha yaxshi. Buning default qiymatda **True** shuning uchun **False** qildik.

`scores = cross_val_score(lr, x, y, cv=kf, scoring=mae)` bu yerda biz mexmon va mezbun sifatida eslab qolsak bo'ladi ya'ni **mae** ni chaqirib olganimiz uchun " siz yozdik. Natijada odatda manfiy ham chiqadi unda `print(-scores)` --> bu esa manfiyni musbat qiladi. `print(-scores.mean())` --> shu orqali o'rtacha arifmetik qiymat topiladi.