

5-dars uchun Report:

Demak birlamchi holatda encoding haqida so'z yuritildi, bunda Handling missing values (mean, mode, median, fixed va drop), undan so'ng esa encoding haqida so'z bordi. Unga tarif berildi quyidagicha; Birorta so'z ko'rinishida berilgan datasetimiz ya'ni umumiy yana ham aniqroq aytsak categorical (string, object) ni numerical (int, float) holatga o'tkazish jarayoni encoding hisoblanadi.

Uning turlari: One-hot encoding, Label encoding, Frequency encoding, Target encoding va Ordinal encodingdir.

1) One-hot encodingda categoricaldan numericalga aylantirishda 0 va 1 dan iborat bo'ladi va bitta ustundagi qiymatlarni har biriga alohida ustun yaratib unga 0 va 1 dan iborat qiymatlarni berib chiqadi.

Bu yerda classlarni tushunib olish ham muhimdri. Ya'ni duplicated bo'lmagan qiymatlardan bittadan vakil oladi. Classlar sonini topish uchun bizga

```
df.nunique()
```

qaysi ustunda qaysi classlar borligini va sonini aks ettiradi.

So'ngra manashu kodlardan fodalangan holda bir ustunni (object, string) ni numerical(int yoki float) ko'rinishiga o'tkazish jarayonidagi kodlar jamlanmasidir:

```
dummies = pd.get_dummies(df['Patient Gender'],
prefix='tasnifli ustun', dtype=int)
```

```
dummies
```

```
df = pd.concat([df.drop(columns=['Patient
Gender']), dummies], axis=1)
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9216 entries, 0 to 9215
Data columns (total 12 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   Patient Id       9216 non-null    object 
 1   Patient Admission Date  9216 non-null    object 
 2   Patient Admission Time 9216 non-null    object 
 3   Merged            9216 non-null    object 
 4   Patient Age      9216 non-null    int64  
 5   Patient Race     9216 non-null    object 
 6   Department Referral 3816 non-null    object 
 7   Patient Admission Flag 9216 non-null    object 
 8   Patient Waittime  9216 non-null    int64  
 9   tasnifli ustun_Female 9216 non-null    int64 
```

```

10  tасnifli ustun_Femalemale   9216 non-null    int64
11  tасnifli ustun_Male        9216 non-null    int64
dtypes: int64(5), object(7)
memory usage: 864.1+ KB

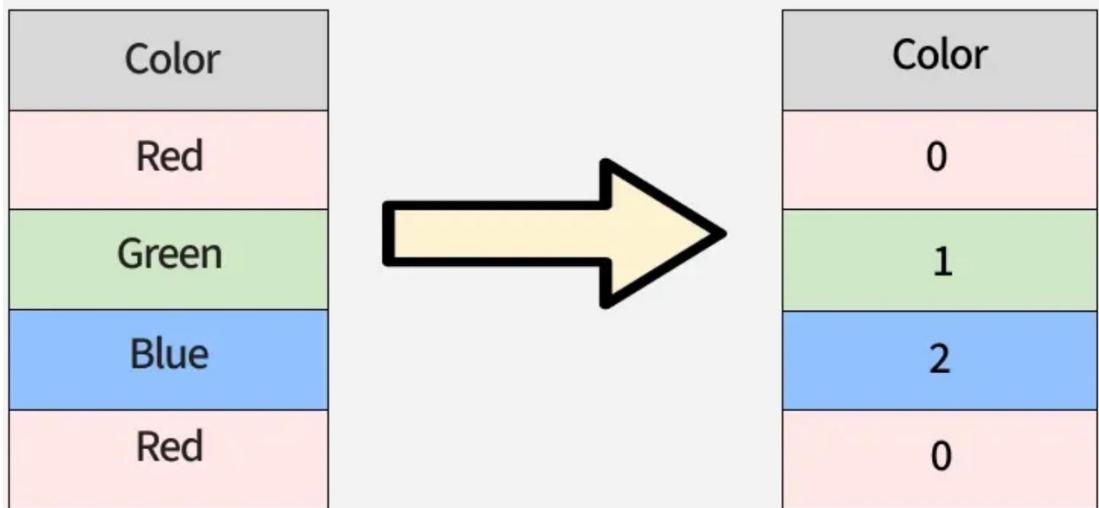
```

shunday ko'rinishda bo'ladi.

O'ng tarafda datasetimizga **dummies** datasetchamizga qo'shimimiz kerakligi sababli bizga **concat()** funksiyasidan foydalanamiz. Va original ustunni tashlab yuborib one-hot encoding qilingan ustunlarni qo'shish uchun **df.drop** dan foydalanamiz. Bu yerda **axis=1** yangi **dummies** ustunlar yoniga qo'shadi. Va e'tibor berishimiz bo'lgan jahha bor, har doim one-code encoding ishlatishdan oldin **df.nunique()** qilib biroz mushohada qilishimiz kerak. Sababi bazida one-hot encoding qilishda datasetimiz collapse holatida bo'lishi mumkin unga sabab ustunlar soni qatorlar sonidan ortib ketkanidir.

2) Label Encoding (tamg'a yoki belgilik) - Categorical qiymatlarni alifbo tartibidagi ketma-ketlikda 0 dan boshlab z gacha nechta qiymat bo'lsa o'shangacha almashtiradi.

Masalan:



uni chaqirishda esa biz sklearn kutubxonasidagi preprocessing moduleni chqariib undan LabelEncode classini import qilayapmiz.

```
from sklearn.preprocessing import LabelEncoder
```

Bu yerda encoder degan o'zgaruvchi va uni chaqrib olayapmiz.

```
encoder = LabelEncoder()
encoder
```

So'ngida esa undan encoding qilishda quyidagi kod orqali foydalanmiz:

```
df['Patient Race'] = encoder.fit_transform(df['Patient
Race'])
```

bu yerda biz tanlagan ustun va uni encoder orqali fit\_transform bilan bir holatdan boshqa holatda transfor qilib olamiz. Va shu bilan birga keyincahlilik biz bir chegara yoki shablon ya'ni datasetmizdan kelib chiqib o'zimiz proporsiya qilib olishmiz uchun bizga **Threshold** kerak bo'ladi. Bu bizga chegarani belgilashda kerak bo'ladi asosan one-hot encodingda.